肺结节 AI 辅助阅片临床验证方案

MRMC 设计 教学版

项目	内容
文档性质	临床验证教学方案，不代表已实施研究、医疗器械临床试验或注册申报资料
研究任务	肺结节检测与定位的 AI 辅助阅片效果评价
主要设计	多中心病例来源、回顾性、全交叉 MRMC、随机两周期两序列交叉阅片研究
版本	V2.0

本方案用于展示研究设计与统计分析思路。所有模拟结果均来自虚构数据，不能作为真实产品性能或临床有效性证据。

附件 C 为当前文件清单；代码实现、运行与软件验证见附件 D

目录

方案摘要 3
一 产品与预期用途 4
二 研究目的与研究问题 4
三 研究设计 5
四 病例与阅片者 6
五 参考标准与空间匹配 7
六 阅片流程与数据采集 8
七 评价终点 8
八 样本量规划 9
九 统计分析计划 10
十 偏倚控制与质量管理 11
十一 伦理与数据管理 12
十二 结果报告与结论边界 12
十三 研究局限与后续工作 13
附件 A AI 独立结节级 FROC 教学分析 14
附件 B MRMC 模拟描述性与教学性推断分析 15
附件 C 当前可复核文件 19
附件 D 代码实现与研究设计 20
参考资料 23

方案摘要

本方案拟评价锁定版本的肺结节 CT 影像辅助检测软件在 AI 辅助阅片条件下，是否能够改善放射科医师对目标肺结节的检测与定位表现。研究采用多中心病例来源、回顾性、全交叉多阅片者多病例设计，并采用随机两周期、两序列交叉阅片安排；同一组阅片者在无 AI 与 AI 辅助两种条件下判读同一批胸部 CT。

主要终点为两种阅片条件下阅片者平均结节级敏感度的差异，关键次要终点为平均每例假阳性数的差异；病例级敏感度与特异度、阅片时间和阅片信心评分作为次要终点。锁定 AI 的结节级敏感度、平均每例假阳性数和 FROC 曲线作为支持性独立性能分析。

正式推断应采用经过验证的 MRMC 方法或适当的混合效应模型，同时处理阅片者、病例、重复测量和扫描内多结节的相关性。本作品所附 Python 代码完成数据质控、描述统计、配对变化图、支持性 FROC 分析和阅片者—病例双重 Bootstrap 教学演示。Bootstrap 结果仅用于理解标准误、95%置信区间和 P 值，不属于经统计师预先确定和验证的正式 MRMC 主分析。

要素	方案安排
产品角色	AI 辅助阅片工具，最终判断由放射科医师作出
主要比较	同一阅片者无 AI 阅片与 AI 辅助阅片
主要终点	阅片者平均结节级敏感度差异
关键次要终点	阅片者平均 FP/scan 差异
支持性分析指标	AI 独立结节级敏感度、FP/scan 和 FROC
不回答的问题	结节良恶性、病理类型、患者结局或产品注册结论

一 产品与预期用途

项目	拟定内容
产品名称	肺结节 CT 影像辅助检测软件（教学设定）
目标用户	具备相应资质并接受产品使用培训的放射科医师
目标人群	符合产品预期用途且已接受胸部 CT 检查的受检者或患者；筛查与诊断性检查的纳入范围应与正式预期用途一致
产品任务	检测并定位胸部 CT 中的目标肺结节，向阅片者提供候选提示
使用方式	在 AI 辅助阅片条件下向阅片者提供候选提示；不得将 AI 输出直接视为阅片者最终结论
主要输出	扫描标识、候选编号、三维位置、检测置信分数及产品规定的其他属性
结论边界	检测置信分数不等同于恶性概率，不能据此评价良恶性或患者结局

目标结节包括经参考标准确认、符合预设定义的实性、部分实性和纯磨玻璃结节。具体最小径、最大径、完全钙化灶及其他排除条件应与产品说明书和临床应用场景一致，并在研究开始前锁定。

AI 软件版本、模型版本、工作阈值、图像预处理和运行环境应在独立验证前锁定。验证病例不得参与训练、调参、阈值选择或匹配规则优化。

二 研究目的与研究问题

2.1 主要目的

比较同一组阅片者在无 AI 与 AI 辅助条件下的结节检出表现，评价 AI 辅助是否提高阅片者平均结节级敏感度。

2.2 关键次要目的

比较两种阅片条件下阅片者平均每例假阳性数，评价敏感度变化是否伴随不可接受的误报负担。

2.3 次要目的

比较病例级敏感度和特异度。

比较阅片时间和阅片信心评分。

描述预设结节特征、中心、设备和阅片者经验亚组中的结果。

2.4 支持性目的

评价锁定 AI 在预设工作阈值下的独立结节级敏感度和 FP/scan，并绘制 FROC 曲线，描述不同置信阈值下检出能力与误报负担的权衡。

三 研究设计

拟开展多中心病例来源的回顾性、全交叉 MRMC 辅助阅片研究，并采用随机两周期、两序列交叉设计。研究使用既有胸部 CT，不改变患者原有诊疗流程。每名阅片者均在无 AI 和 AI 辅助两种条件下判读同一病例集，并随机分配至 AB 或 BA 阅片顺序。

设计要素	安排及作用
多中心病例来源	病例来自不同中心，以覆盖不同人群、设备和扫描参数；实际阅片实施中心应在正式研究前确定
回顾性	使用既有 CT 开展离线阅片，不干预患者原有诊疗
全交叉 MRMC	所有阅片者在两种条件下判读全部病例，便于估计阅片者与病例变异
阅片者内配对	同一阅片者在两种条件下判读同一病例集，减少阅片者能力与病例难度差异的影响
AB 或 BA 随机顺序	将阅片者随机分配至无 AI 后 AI 辅助或 AI 辅助后无 AI 的顺序，以平衡阶段和学习效应
洗脱期	降低对病例和病灶位置的记忆影响
阶段内随机化	重新随机排列病例，降低顺序和疲劳效应

3.1 研究流程

1. 锁定研究方案、软件版本、工作阈值、匹配规则和分析计划。
2. 按照预设规则抽取病例并建立锁定参考标准。
3. 完成阅片者培训和独立于正式研究病例的熟悉阶段。

4. 将阅片者随机分配至 AB 或 BA 阅片顺序，并在各阶段分别随机排列病例，完成第一阶段阅片。
5. 经过预设洗脱期后完成第二阶段阅片。
6. 按照预设空间规则匹配阅片者标记、AI 候选与参考结节。
7. 完成质控、描述统计、正式 MRMC 推断及支持性分析。

四 病例与阅片者

4.1 病例来源与选择

病例应来自多个中心，并按照查看研究结果前预设的纳入、排除和抽样规则选择。病例集应同时包含无目标结节和有目标结节的 CT，并覆盖不同结节大小、密度、位置、形态、病例难度、设备厂商、层厚、剂量和重建参数。

类别	建议预设内容
纳入标准	符合目标人群；完成规定类型的胸部 CT；影像与空间信息满足软件和评价要求；具有合法数据使用授权
排除标准	严重伪影或缺失序列；无法恢复空间映射；不符合目标结节或目标人群定义；其他研究前预设原因
患者去重	预先规定每位患者保留的检查及重复检查处理方式
病例谱	覆盖阴性病例、多发结节及不同大小、密度和位置的目标结节
数据独立	训练、调参、阈值选择和验证数据按患者层面隔离

4.2 阅片者选择

阅片者应具备相应专业资质，并覆盖不同胸部 CT 阅片经验层级。阅片者人数、经验分层、纳入排除标准和退出规则应在研究前确定，不得只保留熟悉 AI 或表现较好的阅片者。

- 统一说明研究任务、目标结节定义和阅片输出要求。
- 使用非正式研究病例完成软件培训和熟悉操作。
- 正式阅片期间不得继续调整培训内容或改变工作阈值。
- 记录缺失阅片、协议偏离和退出原因。

4.3 基础数据表

数据表	核心字段
病例表	case_id、中心、设备、扫描参数、病例标签和病例谱特征
参考结节表	case_id、lesion_id、三维位置或轮廓、直径、密度和其他属性
阅片者表	reader_id、资质、经验、经验分层和随机顺序
阅片结果表	reader_id、case_id、条件、阶段、结节标记、病例判断、时间和信心
AI 候选表	case_id、candidate_id、三维位置、置信分数、软件与模型版本

病例级参考标签定义为一例 CT 中是否至少存在一个符合预设定义的目标结节。本教学数据中的病例级判断按阅片者是否标记任一疑似目标结节生成：TP+FP>0 记为病例级阳性，否则记为阴性。真实研究应由阅片者直接记录病例级判断，并在研究开始前锁定不确定、缺失和不可评价结果的处理规则。

五 参考标准与空间匹配

5.1 参考标准建立

参考标准由多名资深胸部影像医师独立判读并标注。建立参考标准时，专家不得查看 AI 输出或研究阅片者的判读结果，且原则上不兼任研究阅片者。专家意见不一致时，按照预设规则讨论形成一致意见，或由更高资历的专家仲裁。

最终参考标准应形成结节级锁定记录，至少包括去标识化研究编号、参考结节标识、三维中心坐标或分割轮廓、直径、密度及必要属性。该影像参考标准支持评价结节是否被检出和定位，不能单独证明结节良恶性或病理类型。

5.2 空间匹配与重复检出

阅片者标记和 AI 候选使用同一套预设空间规则分别与参考结节匹配。教学规则可采用候选中心位于参考结节三维轮廓内；正式研究应根据产品输出进一步确认距离或重叠度规则。

参考结节与候选采用一对一匹配；未被匹配的参考结节计为漏检，未匹配候选计为假阳性。

多个候选匹配同一参考结节时只计一次检出，可保留最高置信候选为 TP，其余重复候选按预设规则计入 FP。

匹配、边界和重复检出规则必须在查看独立验证结果前锁定并保留审计记录。

六 阅片流程与数据采集

阶段	无 AI 条件	AI 辅助条件
影像显示	使用规定阅片环境查看原始胸部 CT	使用相同阅片环境查看原始胸部 CT 及锁定 AI 候选提示
阅片者操作	独立标记目标结节并完成病例级判断	在 AI 提示基础上自主确认、修改、补充或拒绝候选
记录内容	结节位置、必要置信评分、病例级判断、阅片时间和阅片信心评分	记录内容相同，并保留 AI 提示使用信息
最终判断	由阅片者作出	仍由阅片者作出，不直接复制 AI 输出

阅片环境、显示器、窗宽窗位工具和可使用的临床资料应在两种条件间保持一致。AI 辅助条件除增加 AI 输出外，不应引入其他系统性差异。阅片时间应采用统一起止规则记录。

七 评价终点

层级	终点及解释
主要终点	AI 辅助减无 AI 的阅片者平均结节级敏感度差异，并报告 95%置信区间和预设检验结果
关键次要终点	AI 辅助减无 AI 的阅片者平均 FP/scan 差异，用于判断敏感度提高是否伴随误报负担增加
次要终点	病例级敏感度与特异度、阅片时间、阅片信心评分及其他预设阅片质量指标
支持性分析指标	锁定 AI 在工作阈值下的结节级敏感度和 FP/scan，以及独立 FROC 曲线
亚组分析	按结节大小、密度、位置、中心、设备及阅片者经验等预设因素报告，原则上作为探索性结果

主要终点的差异方向定义为 AI 辅助条件减无 AI 条件。必须报告差异及其不确定性，不能只分别报告两种条件的敏感度。FP/scan 需要与敏感度同时解释，避免通过增加大量可疑标记换取表面上的检出提升。

正式研究开始前，应在统计分析计划中锁定主要终点的优效性假设、最小临床重要差异、显著性水平和判定规则，并为关键次要终点预设 FP/scan 可接受增量及其置信区间判定方式。本教学方案不虚构具体界值；相关数值应根据既往研究、预实验和临床可接受程度确定。若未来要求敏感度改善和 FP/scan 控制同时成立，应将两者设为共同主要终点，并预先规定多重性控制方法。

八 样本量规划

MRMC 样本量应围绕主要终点规划，同时考虑病例数和阅片者数。正式方案不得直接套用普通两组率比较公式，也不能把独立敏感度精度估算中的参考结节数直接当作 MRMC 病例数。

输入参数	来源与作用
无 AI 条件预期表现	来自既往研究、预实验或相近产品资料，构成基线假设
最小重要差异	研究希望可靠检出的最小阅片者表现改善，需要临床依据
病例数与病例谱	决定病例层面信息量，并影响不同难度和结节类型的覆盖
阅片者数与经验结构	决定对阅片者间变异的估计能力
相关结构	包括阅片者、病例、两种条件及同一扫描多结节之间的相关性
显著性水平与统计功效	控制第一类错误，并规定在预设差异真实存在时研究检出该差异的概率
不可评价比例	为缺失阅片、算法失败和不合格病例预留

本教学方案不预设最终病例数或阅片者数。正式样本量应围绕主要终点，综合考虑无 AI 条件下的预期表现、最小临床重要差异、病例数与病例谱、阅片者数量与经验结构、阅片者和病例变异、两种条件及扫描内多结节的相关性、显著性水平、统计功效和不可评价比例。相关参数应来自既往研究或预实验，并由统计人员采用适合 MRMC 设计的专业软件或经验证程序估算。

九 统计分析计划

分析任务	预定方法或规则
数据质控	核对病例、阅片者、条件、阶段、参考结节和 AI 候选的标识、缺失、重复及取值范围
描述统计	报告病例谱、参考结节构成、中心与设备分布、阅片者经验及完成情况
空间匹配	按锁定规则分别匹配阅片者标记和 AI 候选，统一处理重复标记与边界情况
主要分析	估计两种条件下阅片者平均结节级敏感度差异、95%置信区间及预设检验结果
误报分析	比较平均 FP/scan；根据计数分布采用 Poisson 或负二项混合效应模型、GEE 等预先确认的方法
正式 MRMC 推断	对结节级敏感度采用适用于定位任务的 MRMC 方法或预先确认的 GLMM/GEE，处理阅片者、病例、重复测量和扫描内多结节相关性
次要分析	比较病例级指标、阅片时间和阅片信心评分，并明确多重性和探索性定位
支持性分析	计算锁定 AI 的结节级敏感度、FP/scan 和 FROC；不确定性可采用以病例或扫描为重抽样单元的 Bootstrap 方法
亚组与敏感性分析	按预设亚组报告，并评价缺失、算法失败和边界处理对结论的影响
可复核性	记录数据、代码、软件、依赖、参数和分析版本

9.1 当前 Python 代码的作用

当前 Python 代码可以完成数据质量检查、按阅片者与条件汇总结节级敏感度和 FP/scan、计算描述性配对差值并绘制变化图；还可以使用阅片者—病例双重 Bootstrap 演示差异的标准误、95%置信区间和探索性 P 值。它适合作为作品集中的模拟分析附件。

双重 Bootstrap 分别对阅片者和病例进行有放回抽样，并保留无 AI 与 AI 辅助条件的配对关系，用于反映两类抽样变异。该教学方法不等同于根据真实研究主要终点预先确定并验证的正式 MRMC 主分析。

9.2 教学性 MRMC 推断

本教学分析使用 5000 次双重 Bootstrap。95%置信区间采用 Bootstrap 百分位法；探索性 P 值根据点估计和 Bootstrap 标准误进行双侧正态近似计算。

指标	差异 （AI 辅助－无 AI）	95%置信区间	探索性 P 值
结节级敏感度	+6.25 个百分点	-1.44～14.12 个百分点	0.1075
FP/scan	+0.173	0.017～0.320	0.0255
阅片时间	-0.70 分钟	-0.76～-0.64 分钟	<0.0001

在本组虚构数据中，结节级敏感度差异的置信区间包含 0，不能排除总体无差异的可能；FP/scan 增加和阅片时间缩短的置信区间未包含 0。上述结果仅用于学习推断过程，不能作为真实 AI 产品临床有效性或注册结论的证据。

9.3 缺失与失败处理

研究开始前应预设缺失阅片、算法无输出、影像不可读取、参考标准缺失和坐标异常的处理规则。分析时报告受影响的病例、结节和阅片数量及原因，不得根据结果选择性排除。对可能影响主要结论的处理方式开展敏感性分析。

十 偏倚控制与质量管理

主要风险	控制措施
病例选择偏倚	按预设规则从目标人群抽样，覆盖不同中心、设备、结节类型和难度
阅片者选择偏倚	覆盖不同经验层级，统一培训，不根据表现选择性保留阅片者
参考标准偏倚	多名专家独立判读并标注；专家不查看 AI 输出或研究阅片者的判读结果；预设争议解决与仲裁规则，且原则上不兼任研究阅片者。
顺序与记忆效应	采用 AB 或 BA 随机顺序、阶段内随机化和足够洗脱期
培训与学习效应	正式阅片前统一培训和熟悉，正式阶段不持续调整培训
规则事后调整	在查看验证结果前锁定工作阈值、匹配、重复检出和缺失处理规则
数据泄漏	按患者层面隔离训练、调参和验证数据，核对同源数据
失败病例选择性排除	完整记录算法失败、不可评价病例和协议偏离，并按预设规则分析
影像与版本错误	核查 DICOM 序列、空间信息、坐标转换、预处理及数据、模型和代码版本

质量管理应覆盖数据接收、去标识化、序列选择、空间信息核查、参考标准版本、阅片数据导出、AI 运行日志、分析数据生成和结果复核。关键转换步骤应保留可追溯记录。

十一 伦理与数据管理

真实研究开始前，应根据数据来源、研究风险和实施方式向相应机构伦理委员会提交审查或申请相应认定，并分别明确患者知情同意或豁免依据、阅片者知情及信息保护安排。未实际完成的伦理和授权事项必须表述为计划或待确认，不得写成已经批准。

患者 CT 及相关临床资料的收集、使用和处理应具有合法依据，并在进入研究数据集前完成去标识化。

直接身份标识和身份映射表应与研究数据分开保存，研究数据通过去标识化研究编号关联；保留映射表时不得将数据称为完全匿名数据。

规定最小必要访问权限、加密存储、安全传输、备份、保留和销毁方式。

记录参考标准、软件、模型、分析数据和代码版本，保证完整性和可追溯性。

作品集中不附敏感原始数据、患者身份信息或身份映射表。

十二 结果报告与结论边界

正式研究结果应至少报告病例与参考结节构成、阅片者特征、两种条件下的主要与次要指标、主要终点差异及 95%置信区间、FP/scan 变化、支持性 FROC、预设亚组、敏感性分析、缺失与失败情况以及协议偏离。

可以回答	不能直接回答
AI 是否改变阅片者的肺结节检出表现	结节是否为恶性或属于何种病理类型
敏感度变化是否伴随误报负担变化	AI 是否改善患者长期结局
AI 是否可能缩短阅片时间或改变阅片信心评分	产品是否必然通过注册审评
锁定 AI 在独立数据中的检测与定位表现	未纳入研究的人群、设备或场景中的性能

当前研究任务是结节检测与定位，不输出校准后的恶性风险概率，也未定义由风险阈值触发的临床行动，因此 DCA 不纳入主分析。

十三 研究局限与后续工作

本方案为教学型作品，尚未绑定真实产品说明书、真实合作中心和伦理批件。样本量参数和正式 MRMC 推断方法尚需基于预实验并由统计人员确认。

当前 MRMC 附件使用虚构数据，展示描述统计、可视化和教学性双重 Bootstrap 推断；相关置信区间和 P 值不属于正式临床研究结论。当前 FROC 附件使用少量虚构候选，不包含真实影像坐标匹配和不确定性估计。

回顾性离线阅片不能完全代表真实工作流，后续可开展前瞻性研究评价报告时间、召回和患者结局。后续研究需要补充真实或公开结节级数据复现、确定正式样本量、锁定统计分析计划，并选择经验证的 MRMC 或定位任务分析程序。

附件 A AI 独立结节级 FROC 教学分析

本附件使用 5 例虚构 CT、6 个参考结节和 13 个 AI 候选，按预设候选与参考 ID 的对应关系，演示置信阈值筛选、重复检出处理、结节级敏感度与 FP/scan 计算。代码不根据 CT 坐标或分割轮廓执行空间匹配。

阈值	结节级敏感度	FP/scan	解释
0.80	50.0%	0.20	阈值较高，误报较少但漏检较多
0.50	83.3%	1.00	检出更多结节，同时增加误报
0.20	100.0%	1.40	达到最高敏感度，但误报负担进一步上升

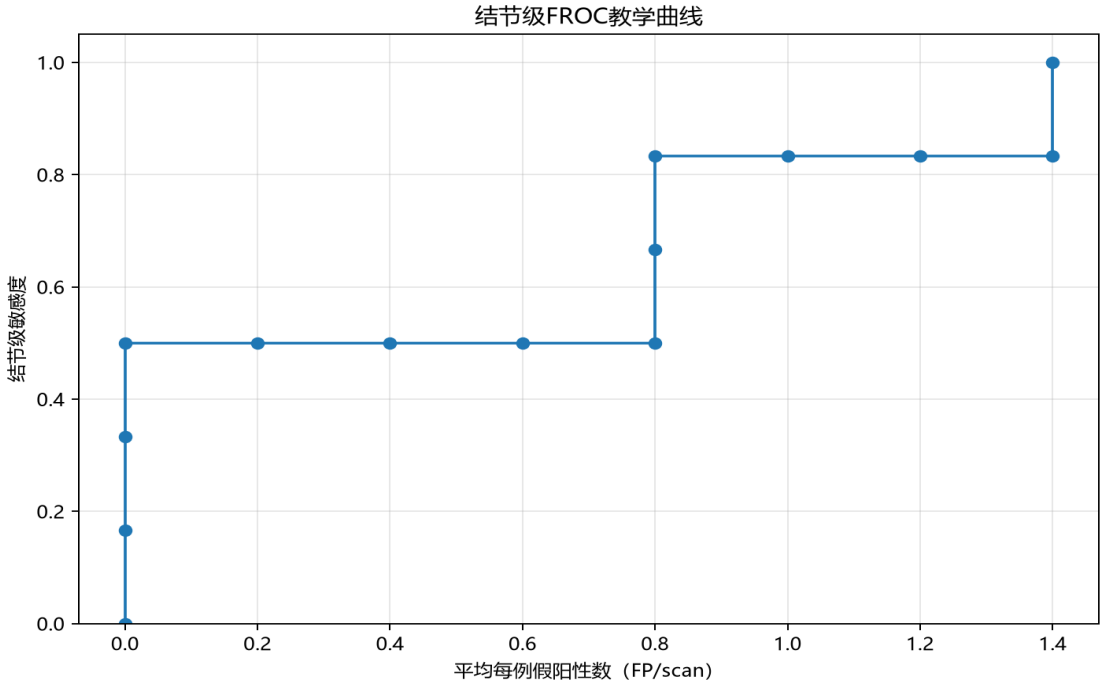


图 1 结节级 FROC 教学曲线

FROC 横轴为平均每例假阳性数，纵轴为结节级敏感度。降低阈值通常提高敏感度，同时增加假阳性。本示例用于演示结节级检测评价的数据结构和计算方法，不能代表真实产品性能或注册证据。

附件 B MRMC 模拟描述性与教学性推断分析

本附件包含 8 名虚构阅片者、80 例虚构胸部 CT 和无 AI、AI 辅助两种阅片条件，共 1280 条阅片者-病例-条件记录。80 例 CT 包括 48 例结节阳性病例、32 例结节阴性病例和 66 个参考结节。23 项预设数据质量检查全部通过。

指标	无 AI	AI 辅助	描述性差值
阅片者平均结节级敏感度	77.5%	83.7%	+6.3 个百分点
阅片者平均 FP/scan	0.51	0.68	+0.17
阅片者平均病例级敏感度	91.4%	93.2%	+1.8 个百分点
阅片者平均病例级特异度	60.9%	49.2%	-11.7 个百分点
阅片者平均阅片时间	4.82 分钟	4.12 分钟	-0.70 分钟
阅片者平均阅片信心评分	3.32	3.70	+0.38

表中病例级结果采用“任一标记即病例级阳性”的教学规则。在本组虚构数据中，AI 辅助条件下平均结节级敏感度较高、平均阅片时间较短，但 FP/scan 较高且病例级特异度较低。这说明辅助阅片评价需要同时解释检出能力、误报负担和效率。

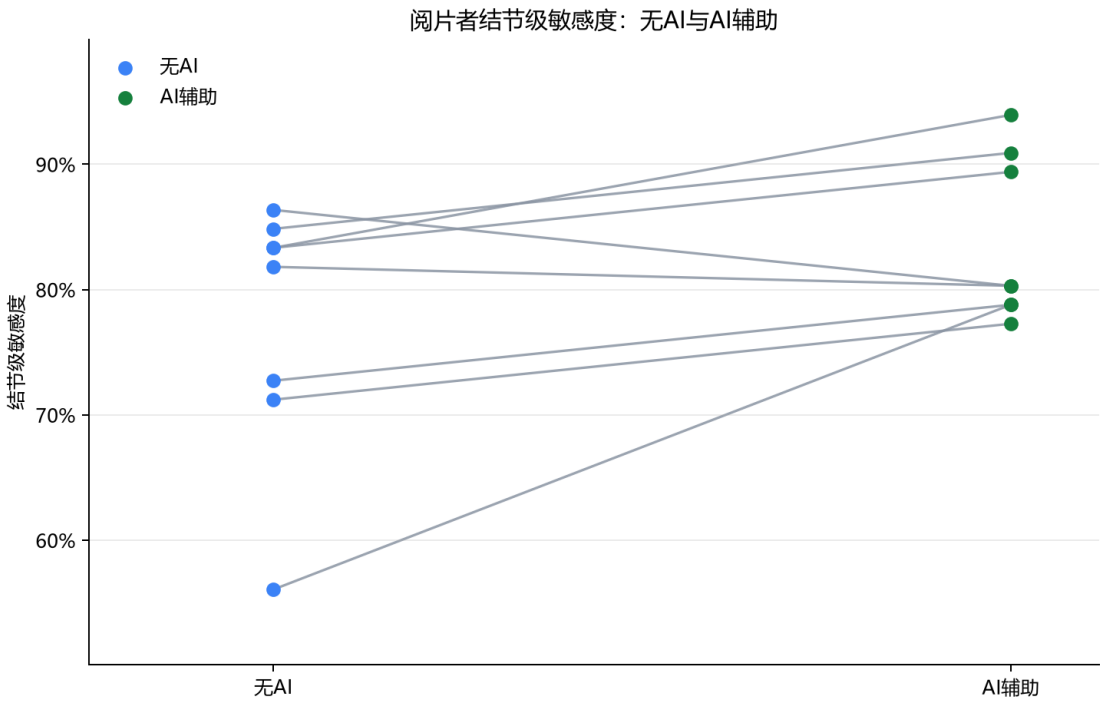


图 2 阅片者结节级敏感度配对变化

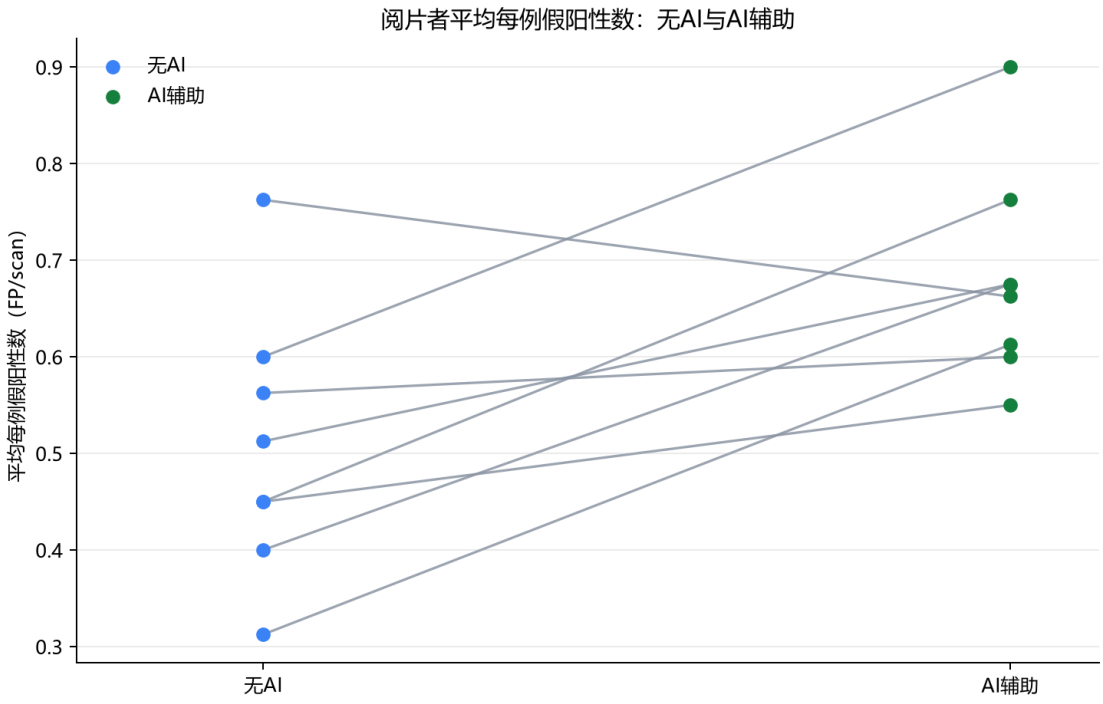


图 3 阅片者平均每例假阳性数配对变化

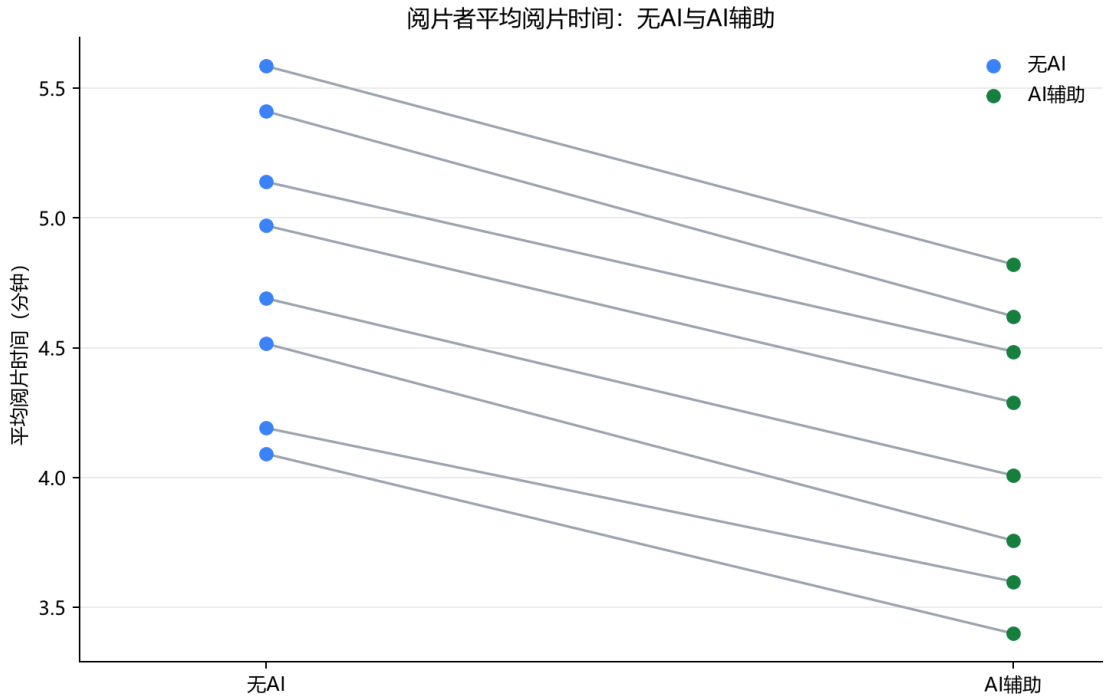


图 4 阅片者平均阅片时间配对变化

上述配对变化图用于描述本组虚构数据中的观察结果。为进一步演示不确定性估计，代码同时对阅片者和病例进行 5000 次有放回抽样，并重新计算两种阅片条件的差异。

指标	差异	Bootstrap 标准误	95%置信区间	探索性 P 值
结节级敏感度	+6.25 个百分点	3.88 个百分点	-1.44～14.12 个百分点	0.1075
FP/scan	+0.173	0.078	0.017～0.320	0.0255
阅片时间	-0.70 分钟	0.03 分钟	-0.76～-0.64 分钟	<0.0001

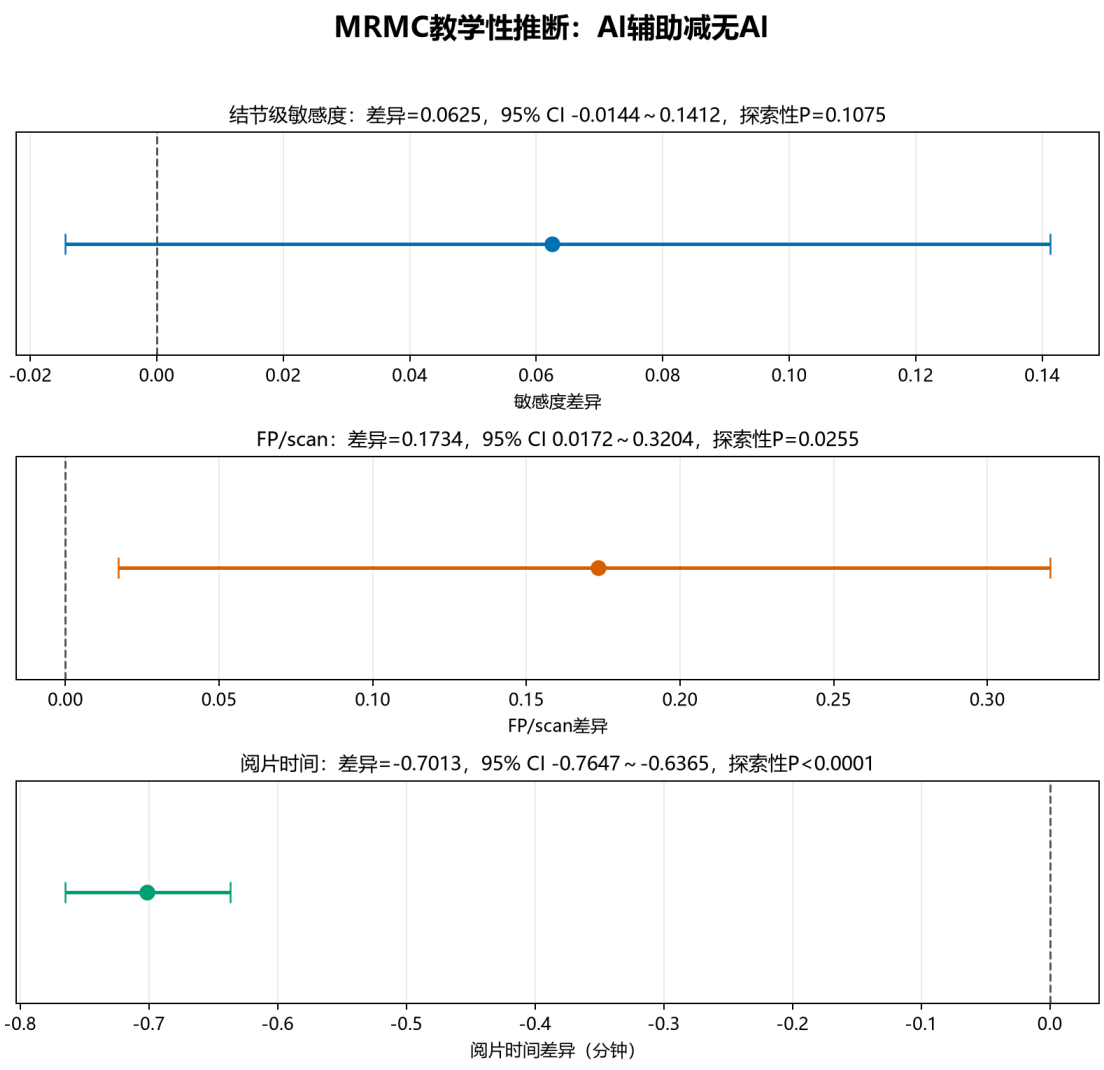


图 5 MRMC 教学性推断置信区间

图中虚线表示差异为 0。结节级敏感度差异的置信区间跨过 0，因此不能排除总体无差异的可能；FP/scan 差异和阅片时间差异的置信区间未跨过 0。该结果由虚构数据生成，只用于理解阅片者和病例抽样变异、置信区间及 P 值，不能证明真实 AI 产品具有临床有效性或临床获益。

附件 C 当前可复核文件

文件或目录	用途
README.md、CHANGELOG.md	项目目的、结果、运行入口及技术变更
requirements*.txt	范围依赖、固定直接依赖、实测完整运行依赖与测试依赖说明
run_all.py	顺序运行四步分析并隔离输出，记录参数、环境及文件哈希
02_统计分析代码/	01 生成模拟；02 描述分析；03 FROC；04 教学推断；study_config.py 与 plot_style.py 为共用配置和绘图模块
tests/	计算公式、配对、异常输入、导出、运行保护和绘图测试
03_模拟数据/	7 份预计算输入 CSV，包含阅片者、病例、配对记录、FROC 数据及数据字典
04_分析结果/	7 份结果 CSV、2 份说明及 6 张图，包括质控、描述性分析、FROC 和教学性推断
docs/	本方案 PDF、running.md、validation.md、protocol-code-amendment.md
.gitignore	本机环境、再生成产物和非源码材料的排除规则

统一入口的运行产物位于新建的 outputs/ 目录，包括 data/、results/、workbooks/、logs/ 和 run_manifest.json。综合工作簿由运行后生成，不作为预计算附件提供。

CSV 内部字段和分类编码保留英文，报告以中文为主。图表检测中文字体，无可用字体时回退英文；绘图语言参数不翻译 CSV、中文报告或 Excel。

附件 D 代码实现与研究设计

研究设计描述真实验证应考虑的要求；当前代码为虚构数据的教学分析，不执行真实影像处理或正式临床验证。方案与代码的对应关系如下。

环节	当前实现与边界
MRMC 数据	8 名虚构阅片者、80 例虚构扫描、1280 条两条件记录；每名阅片者对同一病例有配对结果。
AB/BA 设计	按独立固定种子平衡分配两序列；代码不估计周期或携带效应。
指标汇总	每名阅片者敏感度以参考结节总数为分母，FP/scan 以扫描数为分母，再汇总阅片者指标。病例阳性采用教学规则 TP + FP > 0。
FROC	独立的 5 例扫描、6 个参考结节、13 个候选示例；输入提供匹配 ID，代码校验关系，不计算空间匹配。
重复检出	同一参考 ID 仅计一个 TP，其余重复候选计 FP；阈值 inf 时无候选。
教学推断	同时重抽阅片者和病例，保留两条件配对；95% 区间采用 percentile bootstrap。
探索性 P 值	差异除以 bootstrap 标准误后作双侧正态近似，不是在零假设下构造的 bootstrap 检验。
未实现功能	真实 CT 读取、候选坐标或分割、模型推理、样本量论证与正式 MRMC 主分析。

所有数值由模拟规则生成，不证明真实 AI 产品有效、获益或符合注册要求。FROC 示例不是 80 例 MRMC 的性能曲线。

详细字段见数据字典；当前文件见附件 C；方法解释见 protocol-code-amendment.md。

附件 D 安装运行与输出

实测环境

Windows x64 / Python 3.14.5；NumPy 2.5.1、pandas 3.0.5、Matplotlib 3.11.1、openpyxl 3.1.5。完整运行依赖见 requirements-lock-windows-py314.txt。其他系统或 Python 版本尚未验收。

新机器需先安装 Python。以下命令在项目根目录执行。

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements-lock-windows-py314.txt
.\.venv\Scripts\python.exe -m pip check
.\.venv\Scripts\python.exe run_all.py
.\.venv\Scripts\python.exe -m unittest discover -s tests -t . -v
```

参数	默认值与用途
--simulation-seed	20260920；模拟病例和阅片记录
--sequence-seed	20260921；AB/BA 平衡分配
--bootstrap-seed	20260923；阅片者与病例重抽样
--bootstrap-iterations	5000；至少 2 次，低次数仅用于调试
--plot-language	auto；可指定 en/zh，无中文字体时 zh 明确失败
--output	自动时间命名，或指定尚不存在的新目录

输出与保护

完整运行生成 7 份输入 CSV、7 份结果 CSV、2 份说明、6 张 PNG、1 份 Excel、日志及 run_manifest.json。工作簿在新目录的 workbooks/；清单记录参数、环境、源码及产物哈希和质控状态。

已有目录即使为空也拒绝覆盖；项目内部只允许 outputs/ 下的新子目录。相对输出路径以项目根目录为基准，失败即停。直接逐个运行原脚本会覆盖预计算目录，复现应使用统一入口。入口不能导入真实患者数据。

日志和运行清单可能含机器路径，分享运行产物前应检查。

附件 D 软件验证与解释边界

当前软件验证

当前共 62 个测试方法：在既有 Windows / Python 3.14.5 环境中，61 个通过，1 个因符号链接权限跳过，无失败或错误；pip check 通过。测试覆盖公式、配对、FROC、异常输入、导出、运行保护、字体回退、报告路径和区间绘图。

默认 5000 次流程与“2 次、种子 0”的边界调试均成功，各 23 项数据质控通过。默认 14 份 CSV 与预计算样例字节一致；两次运行各 7 份输入与 16 份分析产物的哈希及 7 份源码哈希一致，报告文件引用有效。各生成 6 张可解码 PNG，Excel 含 15 张工作表，FROC 首行阈值保存为文本 inf。

低次数分析仅用于验证程序行为，不用于统计解释。区间端点与点估计分别绘制，点估计位于百分位区间外时不修改区间或统计数值。

历史环境验证与未验证范围

增加 3 个回归方法之前，已在固定依赖与范围依赖两个全新 Windows / Python 3.14.5 环境运行原 59 个方法（各 58 通过、1 跳过），并完成默认流程及中文/英文图表检查。当前重跑使用既有环境，不表示重新安装环境。历史组合见 docs/validation.md；依赖范围不表示所有组合均已验证。

未执行 GitHub Actions，也未验收其他操作系统或 Python 版本。测试与质控不是临床病例数量、统计有效性证明、安全认证或全面隐私合规审计。

结果解释

默认敏感度差异为 +6.25 个百分点，教学 95% 区间为 -1.44 至 14.12 个百分点，包含 0；阅片时间缩短伴随 FP/scan 增加。教学 bootstrap 和探索性正态近似 P 值不能替代正式 MRMC 主分析，也不能证明真实产品临床有效性。

来源与 AI 工具参与

方案基于 V2.0 教学作品，AI 工具参与资料整理、方案与代码初稿、文字润色、测试及工程适配，不声称全部代码均由作者独立编写。参考资料保留原出处，作为教学背景，不构成现行监管要求的完整核验或医学建议。

参考资料

1. 国家药品监督管理局医疗器械技术审评中心. 肺结节 CT 影像辅助检测软件医疗器械产品注册技术审评报告（受理号：CQZ2000139）[EB/OL]. [2026-09-27]. https://www.cmde.org.cn/（检索受理号 CQZ2000139）.

2. U.S. Food and Drug Administration. K221592 510(k) Summary: AVIEW Lung Nodule CAD [EB/OL]. 2023 [2026-09-27]. https://www.accessdata.fda.gov/cdrh_docs/pdf22/K221592.pdf.

3. U.S. Food and Drug Administration. Clinical Performance Assessment: Considerations for Computer-Assisted Detection Devices Applied to Radiology Images and Radiology Device Data in Premarket Notification (510(k)) Submissions [EB/OL]. 2022 [2026-09-27]. https://www.fda.gov/media/77642/download.

4. U.S. Food and Drug Administration. iMRMC: Software to do Multi-reader Multi-case Statistical Analysis of Reader Studies [EB/OL]. 2025 [2026-09-27]. https://cdrh-rst.fda.gov/imrmc-software-do-multi-reader-multi-case-statistical-analysis-reader-studies.

5. Setio A A A, Traverso A, de Bel T, et al. Validation, comparison, and combination of algorithms for automatic detection of pulmonary nodules in computed tomography images: The LUNA16 challenge[J]. Medical Image Analysis, 2017, 42: 1-13. https://doi.org/10.1016/j.media.2017.06.015.

6. LUNA16 Challenge. Evaluation methodology for pulmonary nodule detection [EB/OL]. [2026-09-27]. https://luna16.grand-challenge.org/Evaluation/.